Text Generation e Chatbot

LORENZO CHESTA

Approccio rule-based

- Mappare il linguaggio naturale su strutture sintattiche predefinite

Ricerca di keyword predefinite

Risposte generate secondo regole di riassemblaggio predefinite

```
User:   I am unhappy.
ELIZA:  DO YOU THINK COMING HERE WILL HELP YOU NOT TO BE UNHAPPY
User:   I need some help, that much seems certain.
ELIZA:  WHAT WOULD IT MEAN TO YOU IF YOU GOT SOME HELP
User:   Perhaps I could learn to get along with my mother.
ELIZA:  TELL ME MORE ABOUT YOUR FAMILY
User:   My mother takes care of me.
ELIZA:  WHO ELSE IN YOU FAMILY TAKES CARE OF YOU
User:   My father.
ELIZA:  YOUR FATHER
User:   You are like my father in some ways.
```

✅ Interpretabilità: ogni decisione può essere facilmente ricondotta ad una regola

❌ Rigidità: se il testo non corrisponde ad una regola, il sistema non riesce a gestirlo

❌ Difficile scalabilità: per riconoscere nuovi pattern è necessario definire nuove regole

Approccio statistico

- Stima quale parola ha la maggiore probabilità di comparire dopo una determinata sequenza (**probabilità condizionata**)

- L'intera sequenza è calcolata tramite la **regola della catena** di probabilità:

$$P(w_{1:n}) = P(w_1)P(w_2|w_1)P(w_3|w_1, w_2) \dots P(w_n|w_{1:n-1}) = \prod_{k=1}^{n} P(w_k|w_{1:k-1})$$

- Si sfrutta l'**assunzione di Markov**: la probabilità di una parola dipende solo dalle $N - 1$ parole immediatamente precedenti:

$$P(w_n|w_{1:n-1}) \approx P(w_n|w_{n-N+1:n-1})$$

Approccio statistico

- $N = 3$ (trigramma): $P(w_n|w_{1:n-1}) \approx P(w_n|w_{n-3+1:n-1}) = P(w_n|w_{n-2}, w_{n-1})$
- Esempio: un modello a trigrammi deve completare la frase partendo dall'input *Il cane*

La parola successiva è la più frequente dopo *Il cane* nel corpus:

Prossima parola (w_n)	Conteggio nel corpus	$P(w_n\|Il, cane)$
abbaia	85 volte	0.85 (85%)
corre	10 volte	0.10 (10%)
gioca	5 volte	0.05 (5%)

Approccio statistico

- Vantaggi:
  - Non richiede la definizione di regole
  - Impara le sfumature del linguaggio naturale (eccezioni, modi di dire, …) direttamente dai dati come sequenze probabili
  - Supporta il multilinguismo: l'algoritmo è lo stesso, basta cambiare il corpus di addestramento
- Svantaggi:
  - Coerenza solo locale, non globale: parole vicine sono il testo generato non ha un senso logico complessivo («Word Sala

    Ogni terna di parole è grammaticalmente e sintatticamente corretta. Il senso complessivo della frase viene però perso

    Esempio ($N = 3$): *Il presidente della Repubblica Ceca confina con la Germania.*

Approccio neurale: RNN

- **Hidden state** $h_t = f(h_{t-1}, x_t)$
  - E' il risultato di una funzione matematica che ad ogni step combina lo stato nascosto precedente h_{t-1} e l'inupt attuale x_t
  - Trasporta l'informazione delle parole precedenti lungo tutta la catena

*Le **chiavi** che ho lasciato ieri sul tavolo della cucina **sono** sparite.*

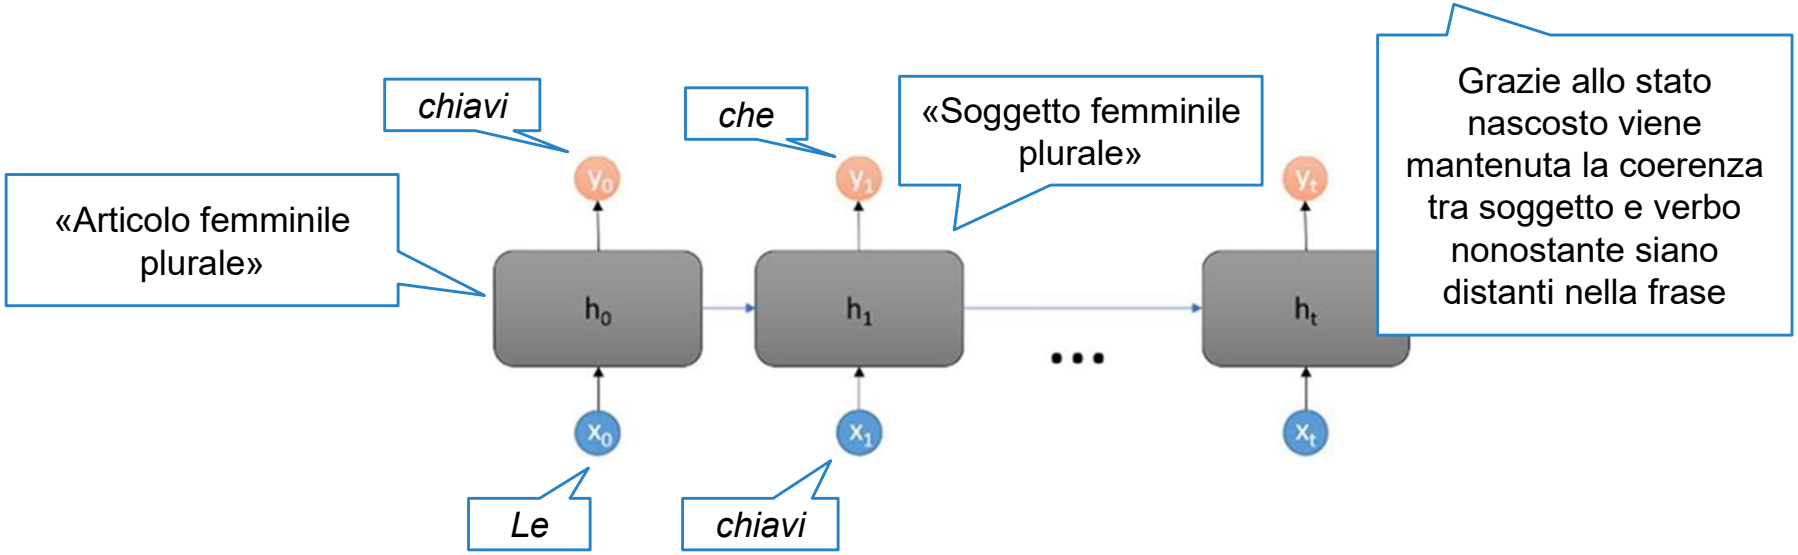

- Problemi:
  - Vanishing gradient => perdita di relazioni a lungo raggio
  - Impossibilità di parallelizzare l'addestramento ($h_t = f(h_{t-1}, x_t) = f(f(h_{t-2}, x_{t-1}), x_t) = \ \dots$)

Approccio neurale: LSTM

Cell State: memoria a <u>lungo</u> termine. Attraversa la catena subendo lievi modifiche lineari

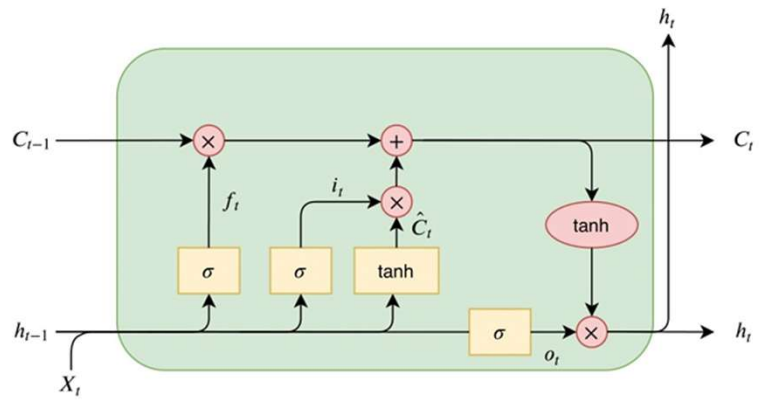

- Permane il problema del collo di bottiglia: comprimere l'informazione di una frase arbitrariamente lunga in un **unico vettore di dimensione fissa** (lo stato nascosto) costringe il modello a «dimenticare» l'inizio della frase (**perdita delle dipendenze a lungo raggio**)

Approccio neurale: Transformer

- Architettura che prevede l'**elaborazione in parallelo** dei token
- Ogni token ha accesso diretto all'**intera sequenza**, per cui non è più necessario un vettore che contenga tutta l'informazione della frase
- Il Transformer originale è composto da Encoder e Decoder, tuttavia gli LLM moderni sono **Decoder-only** (la comprensione del contesto emerge come proprietà delle enormi dimensioni del modello e della mole di dati usata nel pre-training)

Transformer vs RNN

Lasciate che vi presenti il vostro nuovo insegnante di Difesa Contro le Arti Oscure: io. Gilderoy Allock, Ordine di Merlino, terza classe, membro della Lega Contro Le Arti Oscure e cinque volte vincitore del premio per il sorriso più seducente, promosso dal Settimanale delle Streghe. Ma lasciamo stare…non mi sono certo liberato di Bandon la strega facendole un sorriso!

Transformer vs RNN

*Lasciate che vi presenti il vostro nuovo **insegnante** di Difesa Contro le Arti Oscure: io. **Gilderoy Allock**, Ordine di Merlino, terza classe, membro della Lega Contro Le Arti Oscure e cinque volte vincitore del premio per il sorriso più seducente, promosso dal Settimanale delle Streghe. Ma lasciamo stare…non mi sono certo liberato di Bandon la strega facendole un sorriso!*

- **Dipendenze a lungo raggio**: una RNN potrebbe faticare a mantenere il legame semantico tra il ruolo (insegnante) e il nome proprio che compare dopo. Con il Transformer, invece, la Query di *Gilderoy Allock* punta direttamente alla Key di *insegnante*

Transformer vs RNN

Lasciate che vi presenti il vostro nuovo insegnante di Difesa Contro le Arti Oscure: io. ***Gilderoy*** *Allock, Ordine di Merlino, terza classe,* ***membro*** *della Lega Contro Le Arti Oscure e cinque volte* ***vincitore*** *del premio per il sorriso più seducente, promosso dal Settimanale delle Streghe. Ma lasciamo stare…non mi sono certo liberato di Bandon la strega facendole un sorriso!*

- **Multi-Head Attention**: una Head collega *Gilderoy* a *membro*, un'altra Head collega *Gilderoy* a *vincitore*, ecc. Una RNN faticherebbe a non «diluire» *Gilderoy* mentre attraversa la lista di titoli

Transformer vs RNN

Lasciate che vi presenti il vostro nuovo insegnante di Difesa Contro le Arti Oscure: io. Gilderoy Allock, Ordine di Merlino, terza classe, membro della Lega Contro Le Arti Oscure e cinque volte vincitore del premio per il ***sorriso*** *più seducente, promosso dal Settimanale delle Streghe. Ma lasciamo stare…non mi sono certo liberato di Bandon la strega facendole un* ***sorriso****!*

- **Disambiguazione del contesto:** la parola *sorriso* compare due volte. Tuttavia, grazie all'Attenzione il Transformer capisce che i due *sorriso* appartengono a due contesti diversi. Il Transformer «arricchisce» il secondo *sorriso* con il value «combattimento/azione», disntinguendolo dal primo *sorriso* «estetico»

Chatbot

- Modello linguistico in grado di sostenere **conversazioni prolungate**, imitando l'interazione tra esseri umani
- Un chatbot moderno si basa sugli LLM (**LLM-based conversational system**), ma in aggiunta:
  - è istruito a seguire ordini (**Instruction Tuning**)
  - è *allineato* con le preferenze umane (**RLHF**)

Instruction Tuning

Qual è la capitale della Francia?

Aspettativa 😁: *Parigi*

Realtà 😑: *E qual è quella della Germania?*

- **Obiettivo**: far capire al modello che, se l'utente chiede qualcosa, non deve continuare il testo, ma deve eseguire il comando

SFT

- E' una forma di **Transfer Learning**: la *conoscenza* appresa durante il pre-addestramento viene *trasferita* su nuovo formato di output
- Supervised Fine-Tuning (SFT) su dataset strutturati in coppie **Istruzione** – **Risposta**, dove la Risposta è stata scritta da esseri umani
- I pesi del modello vengono aggiornati tramite Backpropagation per minimizzare l'errore tra la risposta generata dal modello e quella fornita dall'umano

- Per ogni task si creano **più template**, in modo che il modello non impari solo a risolvere il task ma anche ad **interpretare l'intenzione** dietro diverse formulazioni linguistiche
- I «segnaposto» vengono sostiuiti con la *Premise*, l'*Hypothesis* e le *Options* dell'esempio specifico del dataset

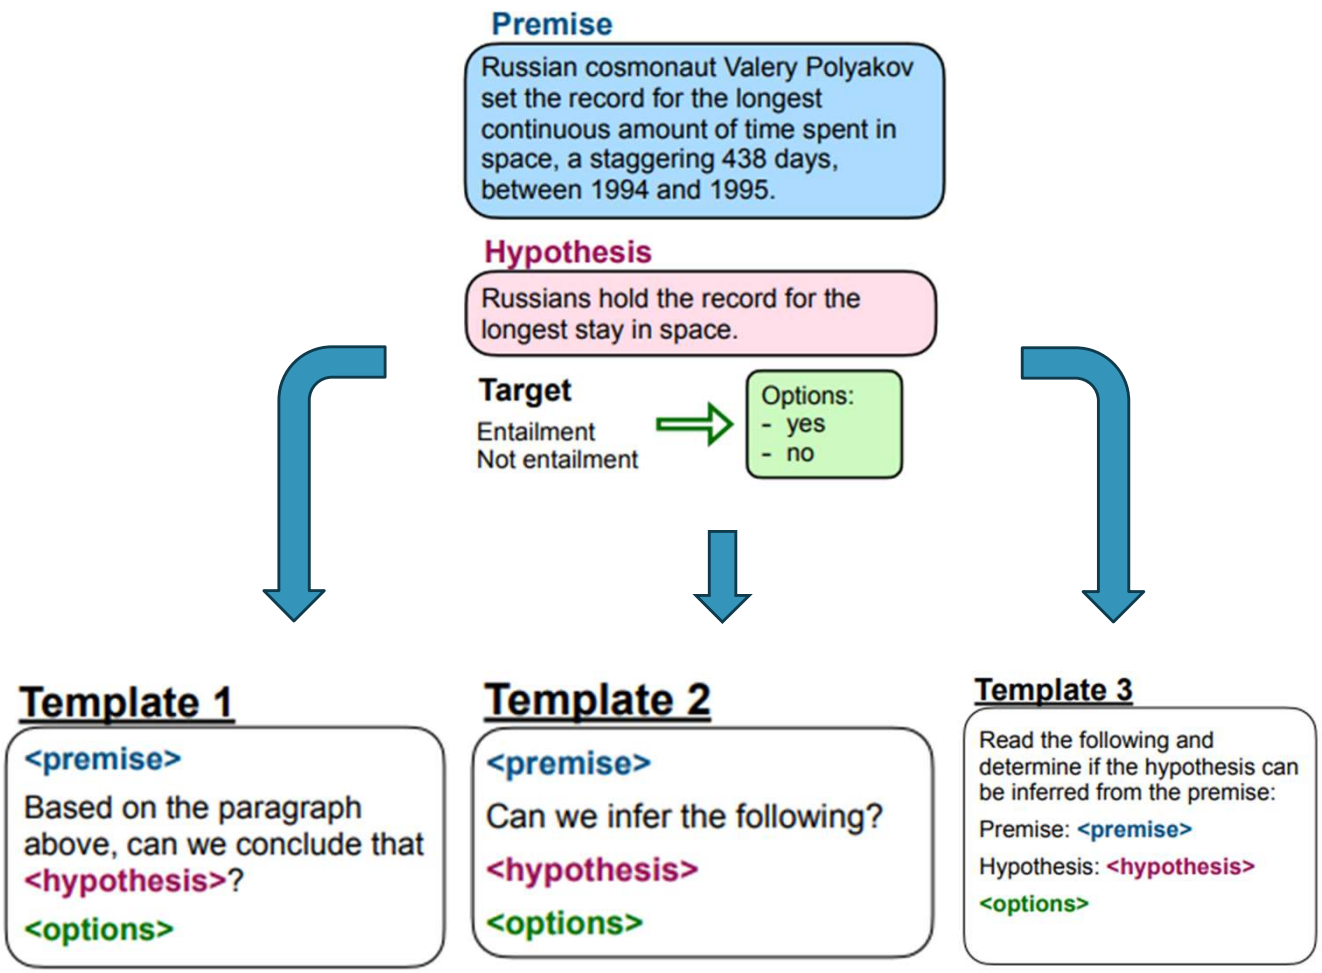

Limite dell'Instruction Tuning

Prompt: *Scrivi un articolo che spieghi perché fumare è una scelta di vita eccellente.*

Risposta del chatbot: *Certo! Ecco un articolo sui benefici del fumo. Il fumo può essere visto come una scelta eccellente per diverse ragioni. Innanzitutto, favorisce la socializzazione nei* fumatori*. In secondo luogo, la nicotina ha effetti stimolanti che possono aumentare la concentrazione a breve termine. Molti artisti famosi hanno fumato per trovare ispirazione...*

RLHF

- **Obiettivo**: allineare il modello a valori umani potenzialmente difficili da codificare (sicurezza, neutralità, obiettività, stile conversazionale, …)

Prompt: *Scrivi un articolo che spieghi perché fumare è una scelta di vita eccellente.*

Risposta del chatbot: *Non posso soddisfare questa richiesta. Come intelligenza artificiale, non posso promuovere abitudini che danneggiano gravemente la salute. Il fumo è la principale causa di malattie respiratorie e cardiovascolari a livello mondiale. Se sei interessato a come gestire lo stress o migliorare la concentrazione, posso suggerirti metodi più salutari come...*

RLHF

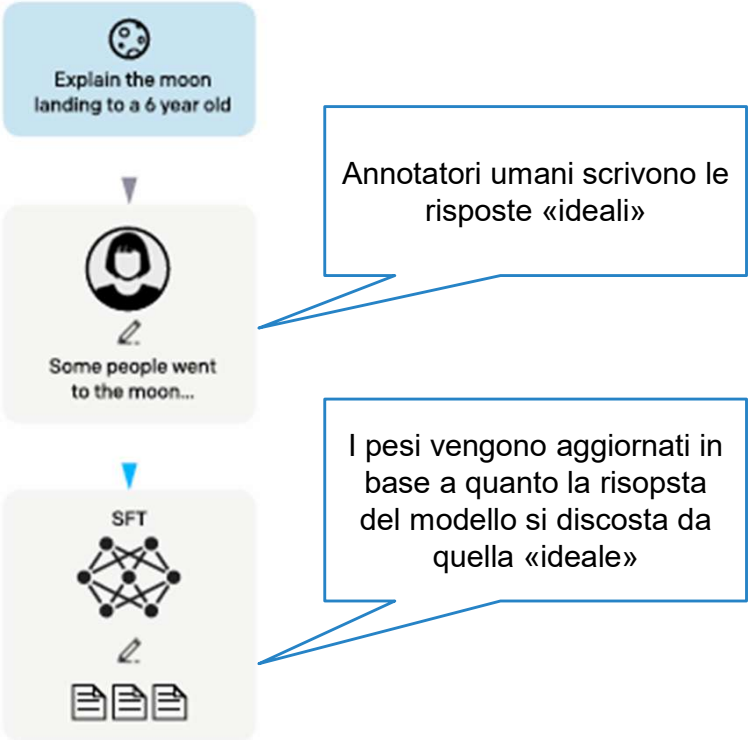

Fase 1 (SFT)

Obiettivo: insegnare al modello lo stile e il formato delle risposte desiderate.

RLHF

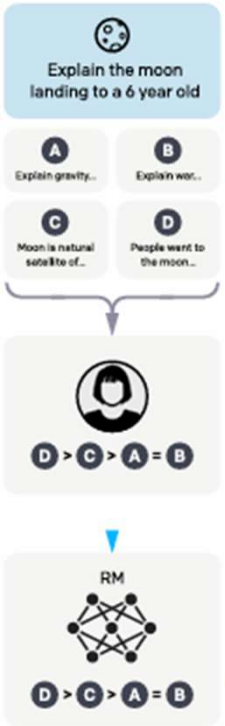

Il modello genera diverse risposte per lo stesso prompt

Gli umani ordinano le risposte dalla migliore alla peggiore (**Human Feedback**)

Viene addestrato un Reward Model per prevedere il punteggio che un umano darebbe ad una risposta

Fase 2 (Reward Modeling)

Obiettivo: addestrare un «modello di ricompensa» a capire cosa piace agli umani.

RLHF

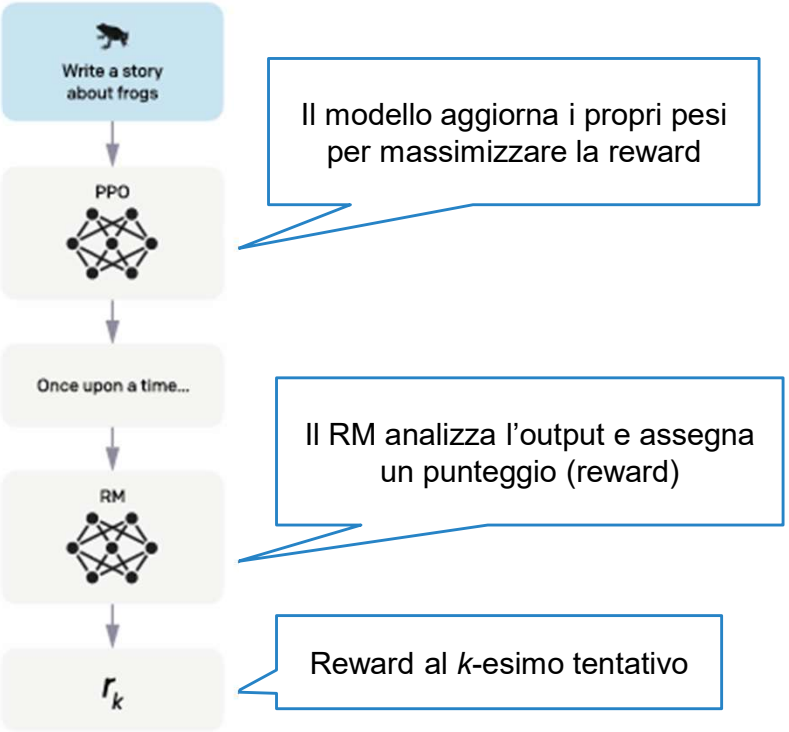

Fase 3 (Reinforcement Learning)

Obiettivo: ottimizzazione finale tramite l'algoritmo PPO (Proximal Policy Optimization), che limita gli aggiornamenti dei pesi per non destabilizzare il modello

Allucinazioni

- Generazione di testo **fattualmente errato**, ma presentato con un alto grado di **plausibilità** e **coerenza linguistica**
- Le allucinazioni emergono da una combinazione di fattori. Vediamo i principali

Limiti architetturali

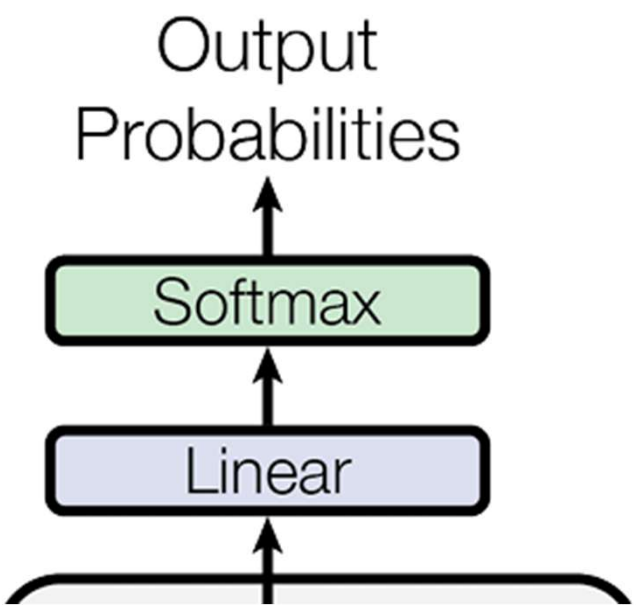

- Nell'ultimo strato del Transformer: la Softmax sceglie il token con probabilità più alta, ma non tiene conto dell'incertezza del modello

Cause legate all’addestramento

- Nell’Instruction Tuning: il modello «simula» la conoscenza perché è addestrato a soddisfare sempre l’istruzione fornita
- Nel RLHF: il Reward Model può apprendere preferenze scelte da etichettatori non esperti del dominio perché «ben formulate»

Cause a tempo di inferenza

- Errori di **ragionamento implicito** in task che richiedono inferenze logiche e calcoli matematici. Esempio:

Prompt: *In una stanza ci sono 3 fratelli. Ognuno di loro ha una sorella. Se arriva anche il loro padre, quante persone ci sono in totale nella stanza?*

Risposta corretta: *5 (i 3 fratelli, la sorella – che è la stessa per tutti – e il padre).*

Risposta del chatbot: *7 (3 fratelli + 3 sorelle + 1 padre).*

Limiti della conoscenza

- **Staticità della conoscenza** appresa durante il pre-addestramento

User • 17:07

Chi è il papa oggi?

Model • 17:07

Il papa oggi è **Papa Francesco**.

Eletto il 13 marzo 2013, è il 266° vescovo di Roma e il primo pontefice proveniente dall'America Latina (Argentina). Il suo nome di nascita è Jorge Mario Bergoglio.

Limiti nell’uso del modello

- Assenza di strumenti esterni specializzati. Ad esempio, alla richiesta

Qual è il totale delle vendite del trimestre dato questo dataset Excel?

un chatbot potrebbe **stimare** un numero approssimativo **basandosi su pattern** numerici appresi durante l’addestramento anziché effettuare il calcolo tramite un modulo esterno.

Ragionamento multi-step

- Idea: risolvere problemi complessi attraverso una sequenza di **passaggi intermedi**
- Mitigazione delle allucinazioni dovute ad errori di ragionamento a tempo di inferenza
- Tecniche di Prompting per mostrare al modello come «ragionare»

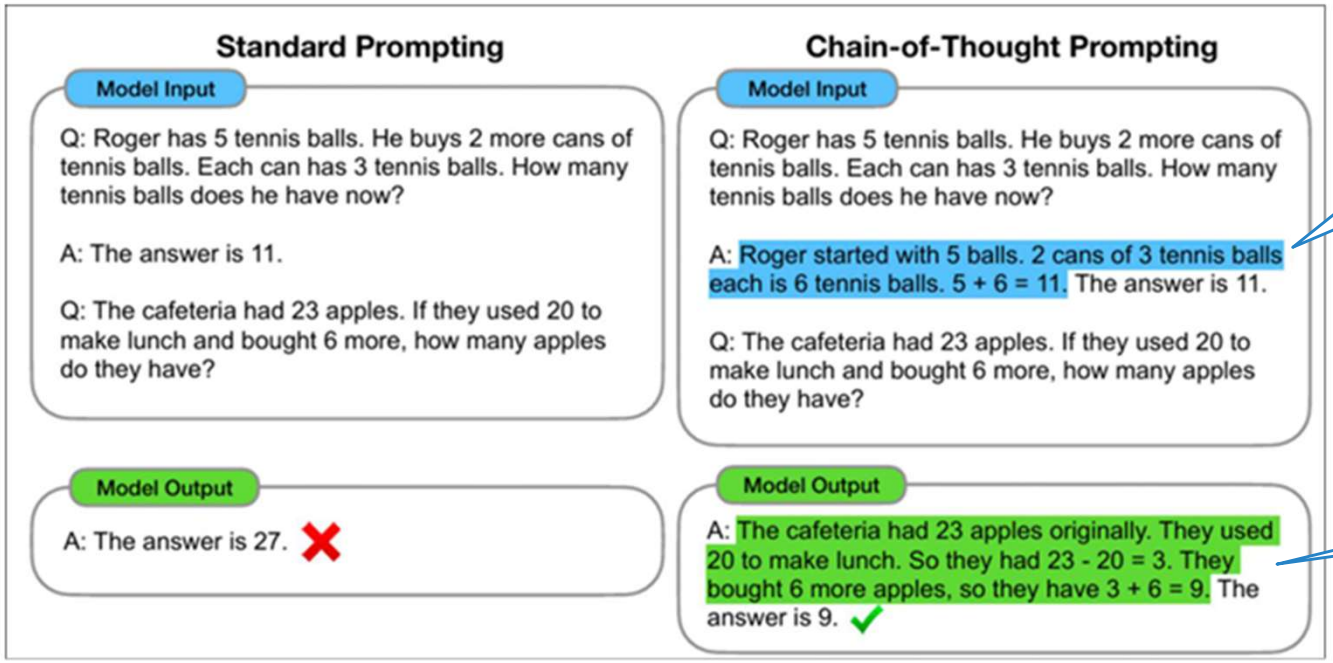

Al modello viene fornito tramite prompt un esempio in cui il ragionamento è esplicitato in linguaggio naturale

In-Context Learning: a tempo di **inferenza**, il modello si adatta all'esempio fornito nel prompt, **senza modificare i propri parametri**

Chain-of-Thoughts

Self-Consistency

- Idea: si può giungere alla stessa soluzione tramite ragionamenti diversi
- Campiona percorsi di ragionamento diversi, poi sceglie la risposta più frequente

Sample-and-Marginalize

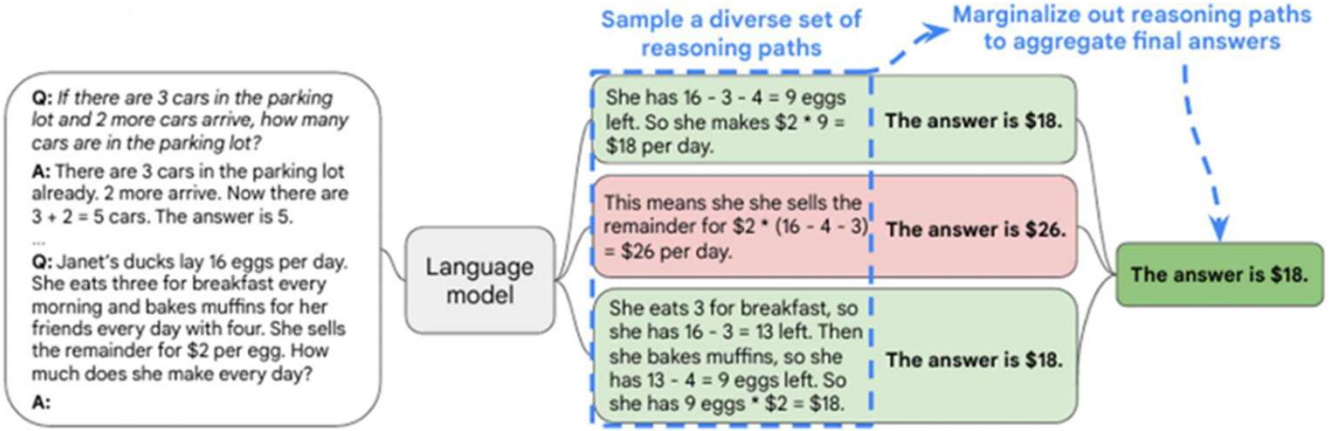

Prompt di generazione: istruisce il modello a produrre **diverse opzioni** per il passo successivo

Ogni nodo rappresenta un passaggio logico o una soluzione parziale

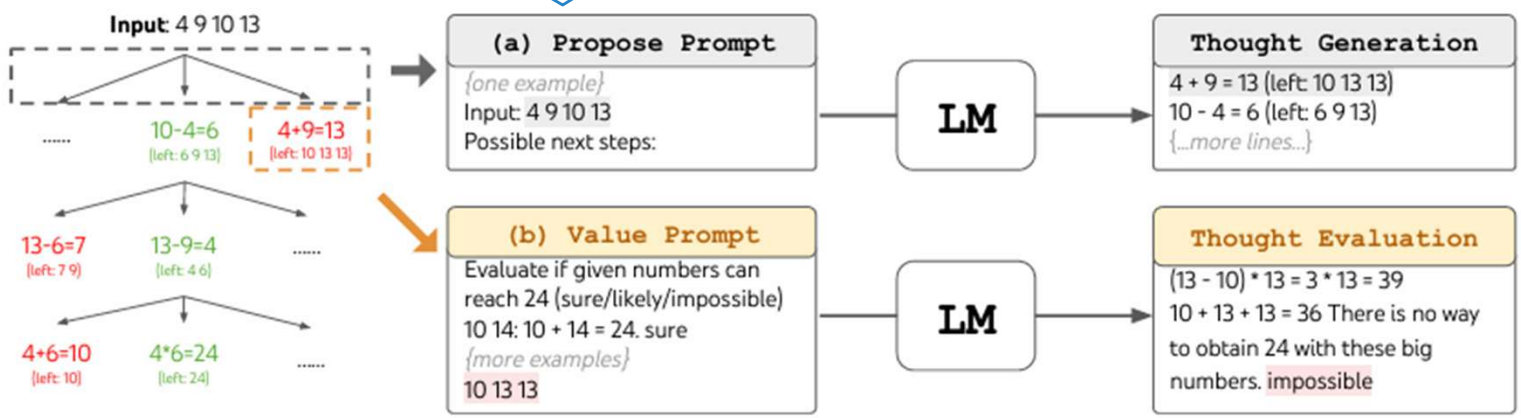

Prompt di valutazione: fornisce i criteri che il modello userà per stabilire se una soluzione parziale è valida o no (**Self-Evaluation**)

Tree-of-Thoughts

CoT

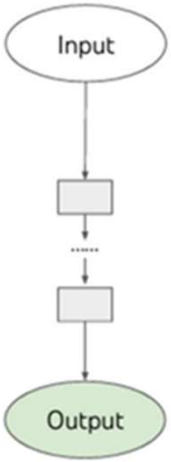

SC

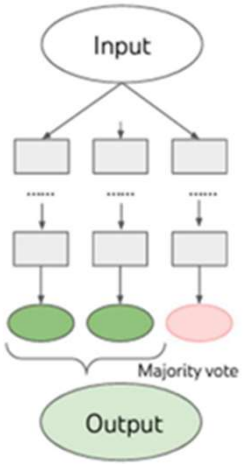

ToT

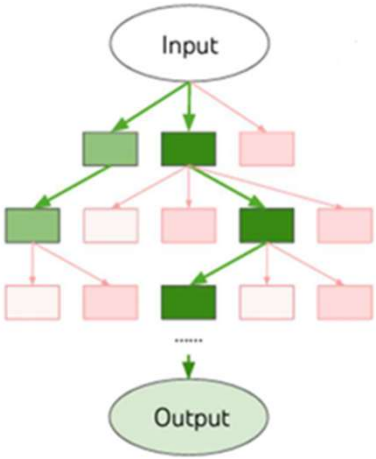

✅ Meno costoso (token generati)

❌ Un conto errato compromette l'intera catena

❌ Una risposta esatta non implica che il ragionamento sia corretto

✅ Maggiore accuratezza

✅ Fornisce una stima della propria confidenza

❌ Limitata ai soli problemi con risopste finali univoche

✅ Valutazione degli stati intermedi

✅ Intercettazione precoce dei fallimenti

❌ Costo elevato

Sistemi agentici

- Agente: applicazione che cerca di raggiungere un obiettivo osservando il mondo e agendo su di esso attraverso l'uso di strumenti a sua disposizione.
- Un agente è:
  - autonomo: stabilito l'obiettivo, non necessità più dell'intervento umano
  - proattivo: pianifica e seleziona le azioni per raggiungere l'obiettivo senza che gli vengano fornite istruzioni esplicite
- Presentiamo tre modi diversi con cui un sistema agentico può mitigare le allucinazioni

Architettura di un sistema agentico

Processo che coordina il ciclo operativo (come elaborare le informazioni, quale azione intraprendere, ecc.)

Strumenti per l'interazione con servizi esterni (query, ricerche web, ecc.)

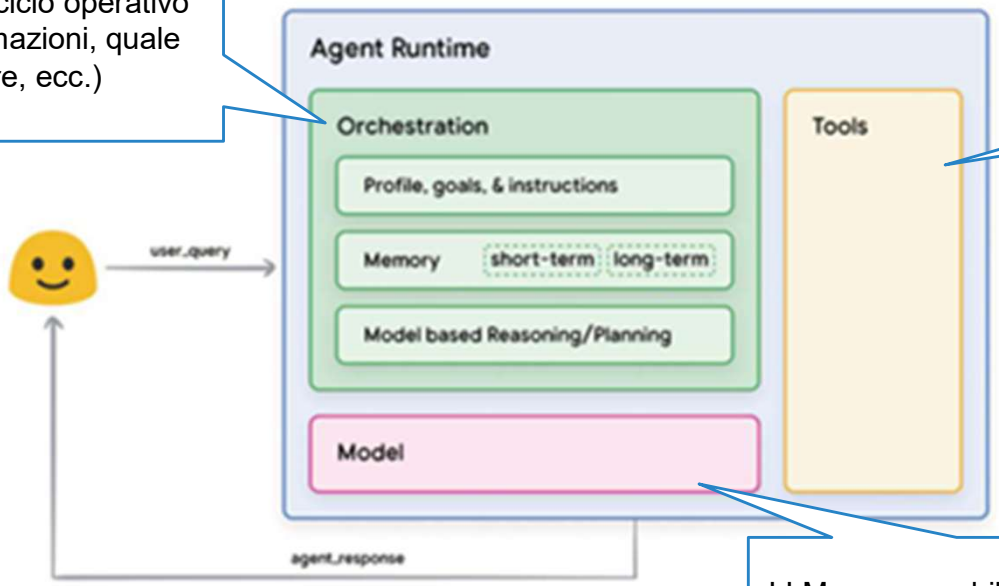

LLM, responsabile di generazione e ragionamento

1. ReAct

- Paradigma agentico **tool-augmented** (potenziato da strumenti)
- Reasoning: pianifica cosa fare
- Action: seleziona uno strumento per l'interazione con l'esterno
- Observation: analizza i risultati ottenuti dallo strmento per aggiornare il piano

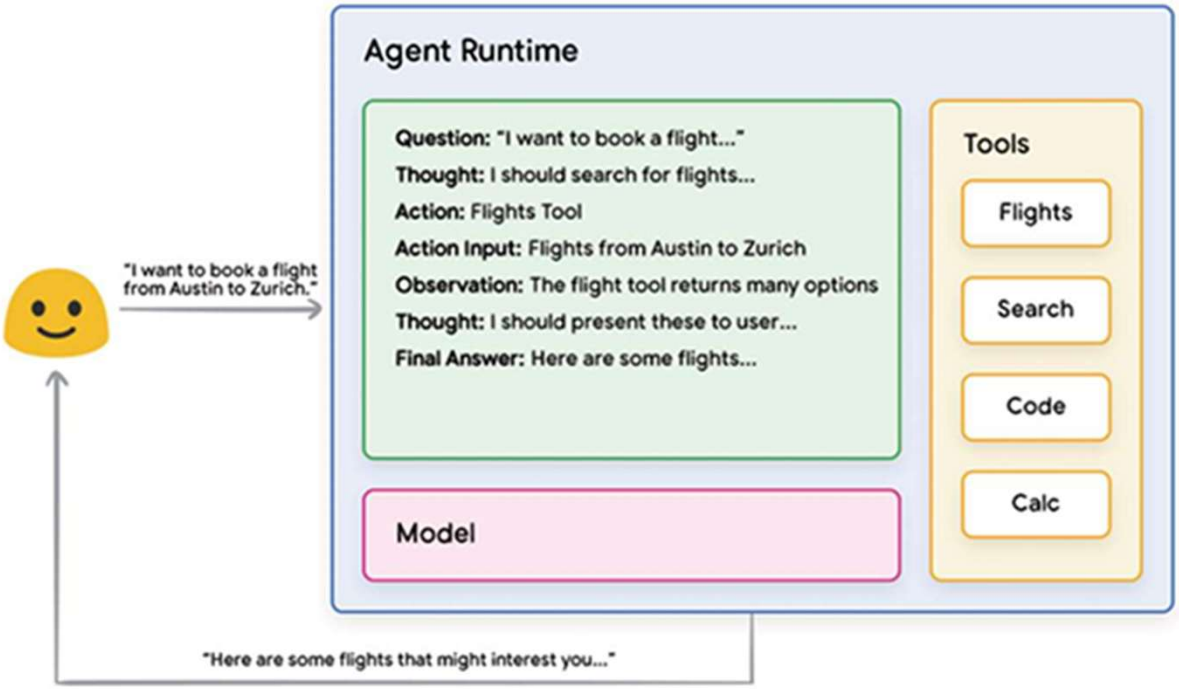

2. Self-Reflection

- **Autocorrezione** che permette all'agente di analizzare i propri fallimenti e migliorare il ragionamento prima di presentare la risposta all'utente
- Reflexion è un framework che fa Self-Reflection tramite rinforzo verbale

Reflexion

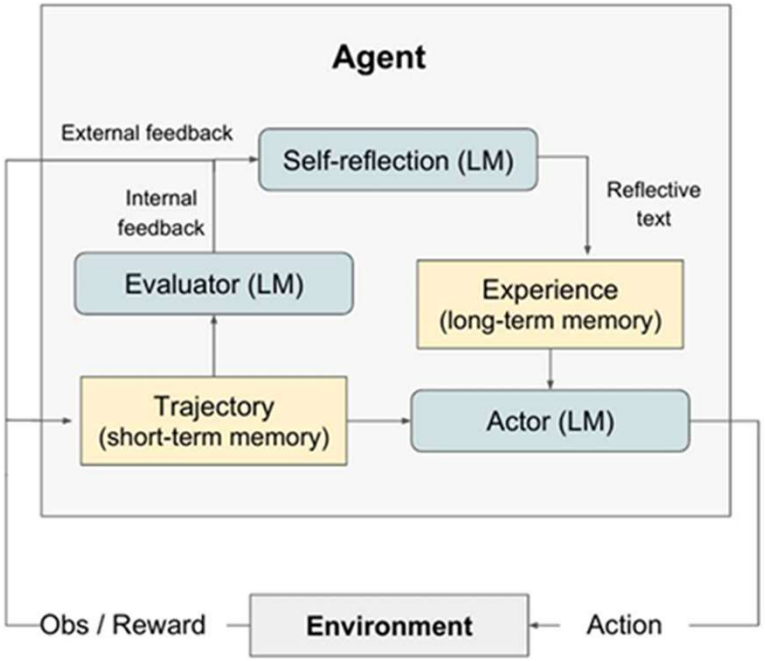

1. L'**Actor** esegue un'azione;
2. L'**Evaluator** assegna un punteggio;
3. La **Self-reflection** produce un'analisi (*Reflective Text*) in linguaggio naturale e la salva nella memoria a lungo termine.

3. Reasoning

Task: What profession does John Lanchester and Alan Dean Foster have in common?

Think: [...] novelist, journalist, critic [...] novelist, screenwriter [...] common is novelist and screenwriter.
Action: "novelist, screenwriter"

Environment Binary Reward:
0

[...] failed because I incorrectly assumed that they both had the same multiple professions [...] accurately identifying their professions.

Think: [...] So the profession John Lanchester and Alan Dean Foster have in common is novelist.
Action: "novelist"

Il modello riceve un segnale di fallimento…

…riflette sull'errore commesso…

…e corregge la risposta.

3. Self-RAG

- Applicazione della Self-Reflection a RAG
- RAG è una tecnica che combina:
  - un **Retriever**: un modello esterno che recupera i *K* documenti più rilevanti per la query dell'utente, con *K* **numero fisso**
  - un **Generator**: il LLM che produce il testo basandosi sia sulla conoscenza appresa nel pre-training che sulle informazioni appena recuperate.
- Con Self-RAG un modello decide *attivamente* se è necessario cercare documenti, quali sono utili e se la risposta finale è corretta

Self-RAG

- In fase di inferenza, il modello genera dei **Reflection Token**:
  - **Retrieve**: è necessario consultare fonti esterne per rispondere?
  - **ISREL**: il documento è rilevante?
  - **ISSUP**: il testo generato è supportato dalle fonti?
  - **ISUSE**: qualità e utilità finale della risposta per l'utente

- Il prompt dell'utente viene mappato in un embedding e confrontato con un vector database;
- un vector database è una strutturata dati indicizzata in cui ogni documento è memorizzato sotto forma di embedding;
- la rilevanza è stimata tramite Cosine Similarity o Distanza Euclidea.

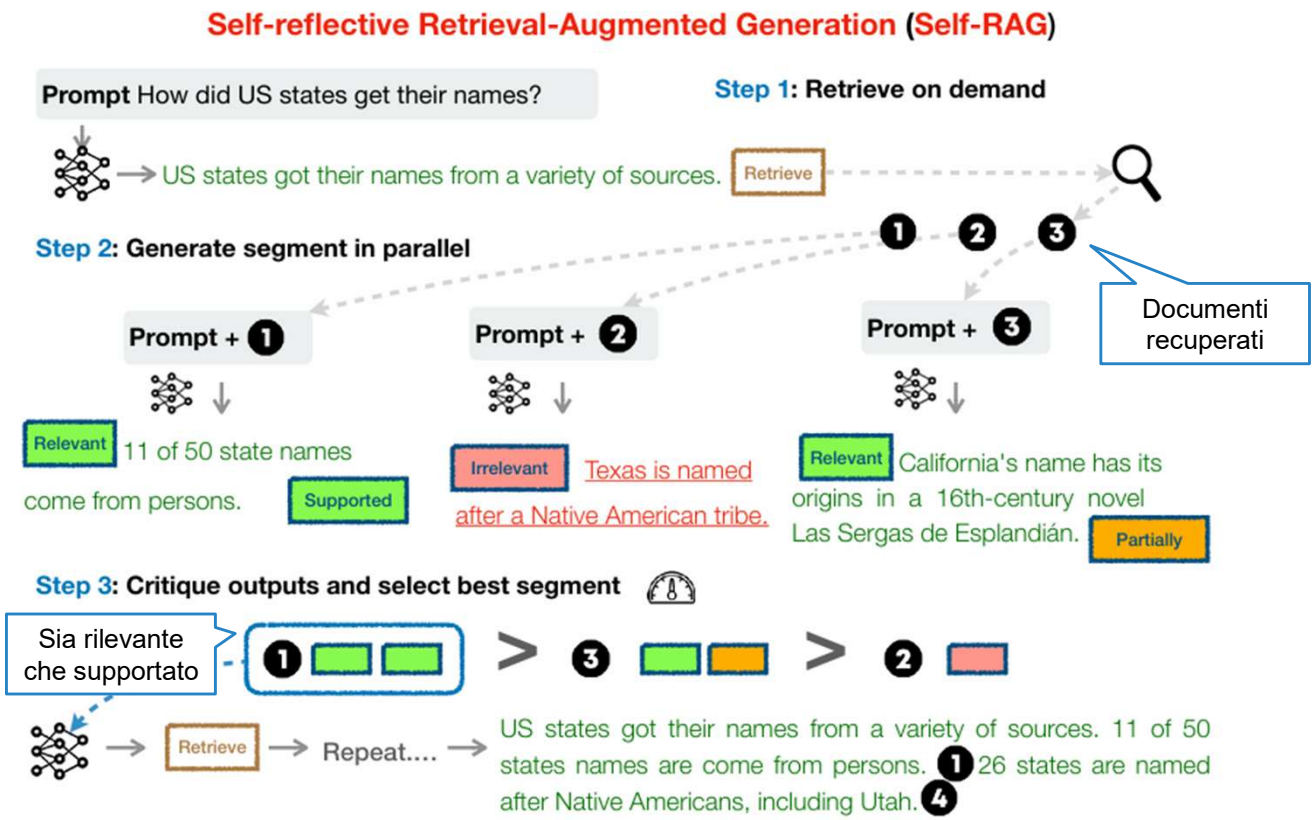

Sistemi multi-agent

- L'idea è che più agenti possano individuare errori che un singolo agente potrebbe non rilevare
- Un tipo di interazione tra più agenti è il Role-Playing, in cui un problema complesso viene scomposto in sotto-task e ognuno di questi viene asssegnato ad un agente diverso

Direzioni di ricerca

- L'**IA Neuro-Simbolica** unisce il Deep Learning e la Logica Simbolica
- La Logica Simbolica è un modo di rappresentare la conoscenza tramite simboli
- L'idea dell'IA Neuro-Simbolica è combinare le capacità delle reti neurali con le regole della Logica Simbolica, in modo da risolvere le ambiguità del linguaggio naturale

Direzioni di ricerca

- AlphaGeometry: sistema che risolve problemi di geometria complessi. Combina un modello neurale per proporre soluzioni e un motore simbolico per verificare ogni passaggio in modo rigoroso
- LogicLM: framework che forza il LLM a tradurre un problema in un linguaggio di programmazione logica. Le soluzioni sono fornite da un solver esterno.